

Veri Bilimi Dönem Projesi Raporu

Proje Başlığı: Yaşam Tarzı ve Fizyolojik Faktörlerin Uyku Kalitesi Üzerindeki Çok Boyutlu Etkisinin İncelenmesi ve Makine Öğrenmesi ile Uyku Bozukluğu Tahmini

Öğrenci: Damla AYDOĞDU

Öğrenci No: 1306210088

Tarih: 03/07/2026

1. Problem Tanımı

Modern yaşamda bireylerin uyku sağlığı, pek çok çevresel ve biyolojik değişkenden etkilenmektedir. Bu projenin temel problemi; yaş, cinsiyet, meslek, uyku süresi (sleep duration), fiziksel aktivite seviyesi (physical activity level), vücut kitle indeksi (BMI category), tansiyon (blood pressure), nabız (heart rate) ve günlük adım sayısı (daily steps) gibi demografik, fizyolojik ve yaşam tarzına bağlı unsurların **uyku kalitesi** üzerindeki doğrudan ve çapraz etkilerini anlamlandırmaktır. Ayrıca, bu metrikler arasındaki ilişkiler çözümlenerek, bir bireyin "Uyku Bozukluğu" (Sleep Apnea veya Insomnia) yaşayıp yaşamadığının önceden tahmin edilip edilemeyeceği araştırılmıştır.

2. Kullanılan Veri Seti ve Kaynağı

Projede Kaggle platformundan alınan açık kaynaklı "**Sleep Health and Lifestyle Dataset**" kullanılmıştır. Orijinal haliyle 374 satır (gözlem) ve 13 sütundan (değişken) oluşan bu veri seti, bireylerin demografik bilgilerini, günlük yaşam alışkanlıklarını ve kardiyovasküler metriklerini içermektedir. Veri seti, hem kategorik (cinsiyet, meslek, uyku bozukluğu türü) hem de sürekli (nabız, günlük adım, stres seviyesi) değişkenleri barındırması bakımından zengin bir keşifsel veri analizi imkanı sunmuştur.

3. Yöntem

Bu çalışma, "Vibe Coding" metodolojisi benimsenerek Google Colab ortamında, bir yapay zeka asistanı (Gemini) ile eş programlama (pair programming) yapılarak yürütülmüştür. İzlenen iş akışı şu şekildedir:

- Veri Ön İşleme ve Temizleme:** Kullanılmayan "Person ID" sütunu düşürülmüş, "Sleep Disorder" sütunundaki boş (NaN) değerler uyku bozukluğu olmayanları temsil edecek şekilde "None" ile doldurulmuştur. "Blood Pressure" değişkeni Sistolik ve Diyastolik olarak iki sayısal değişkene ayrılmıştır. Ayrıca, modeli yanıltmaması adına "Heart Rate" ve "Daily Steps" değişkenlerindeki uç noktalar (outliers) IQR (Çeyrekler Açıklığı) yöntemi ile filtrelenmiştir.

- **Keşifsel Veri Analizi (EDA):** Verinin dağılımını ve değişkenler arası ilişkileri anlamak için saçılım grafikleri (scatter plot), kutu grafikleri (box plot) ve korelasyon ısı haritaları (heatmap) oluşturulmuştur. Daha derinlemesine analiz için 3 ve 4 boyutlu pivot tablolar tasarlanmıştır.
- **Makine Öğrenmesi (Modelleme):** Hastalık tahmini için **DecisionTreeClassifier (Karar Ağacı)** kullanılmıştır. Modelin karmaşıklığını azaltmak amacıyla Özellik Seçimi (Feature Selection) yapılmış, model sadece uykuyu doğrudan etkileyen 4 temel değişkenle (Stres, Nabız, Uyku Süresi ve Uyku Kalitesi) eğitilmiştir.

4. Bulgular

Yapılan görselleştirmeler ve modelleme sonucunda aşağıdaki üç temel araştırma sorusuna yanıt bulunmuştur:

1. **Fiziksel aktivite ve günlük adım sayısı tek başına iyi bir uykuyu garanti eder mi?** Beklentilerin aksine, analizler günlük atılan adım sayısının uyku kalitesi üzerinde doğrudan ve tek başına güçlü bir doğrusal etkisi olmadığını göstermiştir. Fiziksel aktivitenin uyku kalitesini (8.5 ve üzeri puanlar) artırabilmesi için vücut kitle indeksinin (BMI) normal seviyelerde olması gerektiği çok boyutlu ısı haritalarıyla kanıtlanmıştır.
2. **Uyku kalitesini en çok düşüren faktörler nelerdir?** Korelasyon analizlerinde uyku kalitesini en negatif etkileyen iki faktörün **Stres Seviyesi** ve **Nabız (Heart Rate)** olduğu açıkça görülmüştür. Stres ve nabız seviyeleri yüksek olan grupların, 8 saatten fazla uyusalar dahi uyku kalitelerinin düşük kaldığı ve bu gruplarda klinik uyku bozukluğu oranlarının ciddi seviyelerde arttığı tespit edilmiştir. Özellikle "Hemşire" ve "Satış Temsilcisi" meslek gruplarının medyan stres seviyelerinin belirgin şekilde yüksek olduğu gözlemlenmiştir.
3. **Makine öğrenmesi ile basit ve hafif bir tanı modeli kurulabilir mi?** Evet. Tüm verileri kullanmak yerine sadece Özellik Seçimi ile belirlenen en kritik 4 değişken (Stres, Nabız, Uyku Süresi, Uyku Kalitesi) Decision Tree modeline verilmiştir. Model, gereksiz gürültüden (cinsiyet, yaş, meslek vb.) arındırılmış bu odaklı veriyle **%85.33** gibi yüksek bir genel doğruluğa (Accuracy) ulaşmıştır.

5. Sınırlamalar

- **Küçük Örneklem Yanılsaması (Small Sample Size Illusion):** Veriler çok boyutlu analizler için kırılımlara (örneğin; Düşük Stres + Düşük Nabız + Yüksek Uyku Süresi) ayrıldığında, bazı spesifik alt kümelerde yer alan kişi sayısı 1-2 kişi gibi istatistiksel açıdan yetersiz seviyelere inmiştir. Bu durum, o küçük hücrelerdeki hastalık oranlarının %100 veya %0 gibi uç değerlerde görünmesine neden olmuştur.
- **Sınıf Dengesizliği (Class Imbalance):** Veri setinde hiçbir uyku bozukluğu olmayan (None) bireylerin sayısı, "Sleep Apnea" veya "Insomnia" hastalarından çok daha fazladır. Bu durum, modelin hastalık tespiti yaparken (özellikle Apne vakalarında Recall değerinin %69'da kalması) çoğunluk sınıfına eğilim göstermesine yol açmıştır.

6. Öğrenilenler

Bir bilgisayar mühendisliği öğrencisi olarak bu proje, sadece istatistiksel modeller kurmanın ötesinde, gelecekte inşa edeceğim tam kapsamlı web ve mobil uygulamaların arka planındaki "veri bilimi" mimarisini nasıl tasarlamam gerektiğini gösterdi. Özellikle "Feature Selection" (Özellik Seçimi) aşamasında, modeli 15 farklı kullanıcı girdisiyle boğmak yerine sadece en güçlü 4 fizyolojik metrikle eğitmenin, doğruluktan ödün vermeden sistem maliyetini nasıl optimize ettiğini tecrübe ettim.

Bunun yanı sıra, "Vibe Coding" yöntemi ile bir AI asistanını "kodlayıcı", kendimi ise "yazılım mimarı ve kod inceleyici (code reviewer)" olarak konumlandırmam, boş kanvas paralizisini (projeye nereden başlayacağını bilememe durumu) aşmamı sağladı. Hatalı modül çağrılarını ayıklamak, verilerin gerçek hayattaki mantıksal karşılıklarını (45 dakika spor ve 10.000 adım ilişkisi) sorgulamak, kod yazımından çok "mühendislik kararları" vermenin önemini öğretti.